




UNICAMP



Memória em Agentes LLM


Prof. Dr. Julio Cesar dos Reis
dosreis@unicamp.br

Agenda

- ❑ Contexto e definição
- ❑ Gerenciamento de memória
- ❑ Memória de curto prazo
- ❑ Memória de longo prazo
- ❑ Implementação

LLM não possui memória

- ❑ Cada chamada à LLM é independente.
- ❑ O modelo é uma função sem estado
 - mesma entrada, mesma distribuição de saída.
- ❑ Por padrão, as interações são isoladas.



LLM não possui memória



Agente:

Você está Aprovado!

Obtive nota 7,0 na primeira prova e tenho 82% de frequência na disciplina, qual minha situação?



SEM MEMÓRIA / NOVA REQUISIÇÃO

Quanto preciso na próxima prova para ter média 8?



Agente (Sem contexto):

Para responder, preciso primeiro saber as notas que obtive em provas anteriores.

Cada chamada à API do LLM é totalmente independente (stateless). Para manter contexto, o histórico precisa ser reenviado.

LLM é stateless

- ❑ Não produz nenhum estado interno persistente
- ❑ Mesmo modelo, mesmo pesos
- ❑ Nenhuma lembrança

Problemas


- ❑ **Repetição:** o agente pergunta o que já foi respondido, o usuário reintroduz contexto a cada sessão
- ❑ **Perda de preferências:** instruções dadas uma vez ("responda de forma resumida") não sobrevivem à sessão
- ❑ **Não aprende com erro:** a mesma abordagem mal sucedida é tentada de novo, na íntegra

Horizonte temporal exige memória

- ❑ Tarefas de horizonte longo, por exemplo, precisam ser mantida por diversas chamadas a LLM
- ❑ A **memória é o substrato** que sustenta o horizonte longo

Arquiteturas cognitivas

- ❑ No framework CoALA, a memória é um dos módulos estruturantes de uma “arquitetura cognitiva” para agentes de linguagem.



Memória

- ❑ Capacidade de um agente **reter** e **recuperar** informação **entre turnos** e entre **sessões**.
- ❑ É um componente do sistema em volta do modelo.
- ❑ Implica em algumas decisões:
 - O que guardar?
 - Onde guardar?
 - Quando recuperar?
 - Como recuperar?
 - O que 'esquecer'?

Memória de curto prazo

- ❑ Memórias a serem utilizadas dentro da seção, ou seja, com uso imediato.

Memória de longo prazo

- ❑ Memórias a serem utilizadas entre seções, ou seja, memória que tem uso futuro.

Contexto

- ❏ Janela de tokens enviada ao modelo de linguagem em cada chamada
 - contém tudo o que ele pode considerar naquele momento
 - e apenas naquele momento.

Contexto não é memória

❏ O contexto é **volátil** e **exaustivo**

- guardando tudo o que couber enquanto a sessão durar


❏ A memória é **persistente** e **seletiva**

- guardando apenas o que uma política decidiu que vale ser armazenada nela

Contexto não é memória

- ❑ A janela de contexto é **limitada**
- ❑ Modelos mais atuais têm tido aumento no tamanho da janela de contexto
- ❑ Literatura tem mostrado que um contexto maior causa problemas como sobrecarga de contexto.

O problema do 'lost in the middle'



100k tokens

≠

memória.

Janela de contexto vs. memória

	Janela de contexto	Memória
Persistência	Volátil	Persistente
Tamanho	Limitado e fixo	Praticamente ilimitado
Custo	Por token, a cada turno	De armazenamento e de busca

Janela de contexto vs. memória

Contexto	Memória
Janela de tokens	Banco persistente
Temporário	Persistente
Tudo é enviado	Apenas o relevante
Alto custo	Busca seletiva
Some ao terminar sessão	Persiste

Conhecimento paramétrico vs. contexto vs. memória

❏ Conhecimento paramétrico

- LLM sabe: Paris é capital da França

❏ Contexto

- O usuário perguntou sobre França.

❏ Memória

- Este usuário sempre prefere viajar de trem.

Gerenciamento da memória

Gerenciamento de memória

- ❑ As operações de escrita, recuperação, atualização e esquecimento formam o ciclo de vida de qualquer memória
- ❑ Sem as quatro, o agente ou não guarda, ou não acha, ou acumula lixo (memórias irrelevantes).

Operações de gerenciamento



Escrita

Decidir o que merece ser guardado, e em que forma as informações serão registradas.



Recuperação

Trazer de volta o que é relevante para **esta** tarefa em execução no momento.



Atualização

Reconciliar memória antiga com informação nova, mantendo o conhecimento consistente.



Esquecimento

Remover o que ficou obsoleto, redundante ou incorreto para liberar espaço e foco.

Escrita



Escrita

Decidir o que merece ser guardado, e em que forma as informações serão registradas.

Escrita

- ❑ Nem tudo merece “virar memória” (ser armazenado)
 - A maior parte de uma conversa é descartável.
 - A operação de escrita visa decidir o que vale ser guardado e em que forma.
- ❑ Formas possíveis
 - texto livre, campo estruturado, par pergunta /resposta.
- ❑ **Escrever demais** é tão ruim quanto **não escrever**
- ❑ “Memória inchada” piora a recuperação

Recuperação



Escrita

Decidir o que merece ser guardado, e em que forma as informações serão registradas.



Recuperação

Trazer de volta o que é relevante para **esta** tarefa em execução no momento.

Recuperação

- ❑ Recupera o que é relevante para a tarefa
- ❑ Habitualmente, pode ser feita por chave e por busca semântica.
- ❑ **Por chave:** eu sei exatamente o que quero, "as preferências do aluno 123"
- ❑ **Por similaridade semântica:** eu não sei a chave, sei o assunto

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \|y\|}$$

similaridade cosseno

Atualização



Escrita

Decidir o que merece ser guardado, e em que forma as informações serão registradas.



Recuperação

Trazer de volta o que é relevante para **esta** tarefa em execução no momento.



Atualização

Reconciliar memória antiga com informação nova, mantendo o conhecimento consistente.

Atualização

- ❑ Reconciliar o que já estava armazenado na memória com informações novas:
 - Ex: A informação mudou: a nota era 7,0, agora é 8,5 → **substituir**
- ❑ Três políticas: **sobrescrever**, **acumular** ou **consolidar**
- ❑ Sem atualização, o agente age com informação desatualizada

Esquecimento



Escrita

Decidir o que merece ser guardado, e em que forma as informações serão registradas.



Recuperação

Trazer de volta o que é relevante para **esta** tarefa em execução no momento.



Atualização

Reconciliar memória antiga com informação nova, mantendo o conhecimento consistente.



Esquecimento

Remover o que ficou obsoleto, redundante ou incorreto para liberar espaço e foco.

Esquecimento

- ❑ A memória tende a crescer com informações redundantes ou ruidosas
- ❑ Importante o processo de esquecimento dessas memórias
- ❑ Memória que só cresce vira ruído
 - Quanto mais entradas, **pior a recuperação**.
- ❑ Remover o que ficou **obsoleto, redundante** ou **incorreto**
- ❑ Critérios possíveis
 - idade, desuso, contradição com memória mais recente.


Fluxo de Interação e Memória



**Memória de curto prazo
(incluindo memória de trabalho)**


Memória de curto prazo

- ❑ O histórico da sessão atual
 - mensagens, chamadas de ferramenta e seus resultados.
- ❑ Reenviada a cada chamada ao modelo.
- ❑ Ao encerrar a sessão, desaparece por completo.



Memória de trabalho

- ❑ Inspirada na psicologia cognitiva
- ❑ Mantém e manipula temporariamente a informação em uso



Memória de trabalho

- ❑ É o que o agente está **usando agora**
- ❑ Objetivo corrente, plano em execução, resultados intermediários, memórias recuperadas
- ❑ Contém informação
 - nascida nesta sessão
 - trazida de memórias de longo prazo

Estado (*state*) como memória de trabalho

- ❑ **State** como contrato entre nós do grafo
- ❑ Memória de trabalho materializada
- ❑ Deixa de ser implícita no histórico e passa a ser explícita e tipada

Estado (*state*) como memória de trabalho

- ❑ Reúne, no mesmo lugar, o que nasceu na sessão e o que veio do **store (memória de longo prazo)**
 - o estado não distingue origem
- ❑ Cada nó lê o estado, produz uma atualização
- ❑ o *reducer* decide como combiná-la

- ❑ **Dois termos (Mesmo elemento):**
 - “estado” para quem projeta o grafo
 - “memória de trabalho” para quem estuda o agente

Limitações e desafios

- ❑ **Tamanho finito:** a janela tem limite, e tarefas longas o ultrapassam
- ❑ **Custo recorrente:** o histórico é reenviado e cobrado a cada chamada, cresce a cada iteração.

Limitações e desafios

- ❑ **Tamanho finito:** a janela tem limite, e tarefas longas o ultrapassam
- ❑ **Custo recorrente:** o histórico é reenviado e cobrado a cada chamada, cresce a cada iteração
- ❑ ***Lost in the middle:*** a atenção degrada no meio de contextos longos; informação presente não é informação usada
- ❑ **Volatilidade:** ao fim da sessão, tudo se perde

Limitações e desafios

- ❑ Tamanho, custo e atenção pioram **dentro** da sessão
- ❑ Volatilidade só se resolve com memória de longo prazo

Estratégias gerais de gestão

- ❑ **Truncar:** descartar mensagens antigas.
- ❑ **Janela deslizante:** manter apenas as n últimas.
- ❑ **Sumarizar:** condensar o histórico antigo, preserva sentido.

Memória de longo prazo

Memória de longo prazo

- ❑ Informação que **sobrevive ao fim da sessão** e pode ser recuperada em qualquer sessão futura
- ❑ Vive fora do contexto, em um repositório externo
 - ex: como vectors stores
 - só entra na janela quando **recuperada**.
- ❑ A taxonomia vem da psicologia cognitiva (Tulving, 1972)
 - Foi adotada pela literatura de agentes
 - Empréstimo terminológico, não afirmação de equivalência cognitiva

Tipos

❏ Semântica (Fatos)

- Usuário trabalha na Unicamp

❏ Episódica (Experiências)

- Na semana passada o usuário pediu um relatório.

❏ Procedural (Como executar)

- Sempre utilizar ferramenta X para consultar ERP.

Memória semântica

- ❑ Fatos e conhecimento sobre o usuário, o domínio ou o próprio agente
- ❑ Não importa *quando* foi aprendido
- ❑ Importante é que seja um “fato que é verdade”.

Memória semântica – Estruturas

❏ *Profile*

- um documento único que se atualiza
- Visão coerente, fácil de injetar inteiro

```
{  
  "aluno_id": "2024-1187",  
  "nome": "Marina",  
  "curso": "Engenharia de Computação",  
  "disciplinas": ["MC886", "MC921"],  
  "preferencia_resposta": "concisa",  
  "tratamento": "informal"  
}
```

Memória semântica – Estruturas

Collection

- muitos registros independentes
- fácil de escrever, recuperação seletiva

```
[  
    "Marina cursa Engenharia de  
    Computação",  
    "Marina está matriculada em MC886  
    e MC921",  
    "Marina prefere respostas  
    concisas",  
]
```


Memória episódica

- ❑ **Experiências:** o que aconteceu em interações passadas, com seu contexto.
- ❑ **Datada e situada**
- ❑ Ao contrário da semântica, o *quando* importa

Memória episódica – Estruturas

- ❏ Guarda a conversa exatamente como aconteceu
- ❏ **Barato de escrever**
 - basta persistir
- ❏ **Caro de reusar**
 - recuperar dezenas de turnos para extrair uma lição gasta contexto e dilui o sinal

Memória semântica vs. Memória episódica



Memória episódica – Estruturas

[2026-07-20 · thread 8f2a]

Marina: qual minha situação em MC886?

Agente: [consulta notas] 7,0 · [consulta frequência] 82%
[consulta pendências] indisponível

Agente: Nota 7,0, frequência 82%. Pendências fora do ar. Foque na entrega final.

Marina: valeu, era isso mesmo

Memória episódica – Estruturas

- ❑ Condensa a interação em situação, ação e resultado
- ❑ **custa uma chamada** de extração na escrita
- ❑ devolve um **registro pronto** (recuperado como exemplo)

```
{  
  "episodio_id": "ep-0341",  
  "data": "2026-07-20",  
  "aluno_id": "2024-1187",  
  "situacao": "Perguntou sobre sua situação na disciplina MC886",  
  "acao": "Consultei notas, frequência e pendências. Pendências  
          indisponíveis; avisei e segui com o restante.",  
  "resultado": "Aluna satisfeita; pediu para focar na entrega final",  
  "aprendizado": "Quando pendências falham, seguir com os demais dados em vez  
                 de interromper"  
}
```

Memória procedural

- ❑ Como agir
 - regras, instruções, políticas de comportamento
- ❑ Não é sobre o mundo, é sobre o próprio agente.

- ❑ Pode ser explícita ou implícita.
 - **Implícita:** os pesos do modelo, procedimentos adquiridos no treinamento
 - ❑ **fixa** em tempo de execução
 - **Explícita:** prompt de sistema, skills, regras e o próprio código do agente
 - ❑ editável pelo agente

Comparação memórias de longo prazo

Tipo	O que guarda	Analogia
Semântica	Fatos	O que eu sei
Episódica	Experiências	O que eu vivi
Procedural	Regras, métodos	Como eu faço

Memória e outros componentes


- ❑ Reasoning usa memória.
- ❑ Planning consulta memória.
- ❑ Reflection gera memória.
- ❑ Skills podem escrever memória.
- ❑ Deep Agents dependem fortemente dela.

Implementação em LangGraph

Arquitetura Geral



Fluxo




Três camadas

- ❑ **Estado:** carrega a memória de trabalho durante a execução
- ❑ **Checkpoint:** persiste por thread e sustenta o curto prazo entre turnos
- ❑ **Store:** guarda a memória de longo prazo
 - acessível de qualquer sessão

Três camadas

- ❑ **Estado:** a memória de trabalho, viva durante a execução do grafo
- ❑ **Checkpoint:** o estado persistido, indexado por `thread_id`
- ❑ **Store:** persistência entre threads, indexada por `namespace`



Checkpointer

- ❑ Salva o estado completo do grafo a cada *super-step*
- ❑ Indexado por **thread_id**, uma thread é uma sessão
- ❑ Ao invocar o grafo com a mesma thread, o estado é restaurado automaticamente.
- ❑ *Backends*: memória, SQLite, Postgres
- ❑ Sem *checkpointer*, cada **invoke** começa do zero


Checkpointing – Vantagens

- ❑ **Retomada:** uma execução interrompida no passo 30 recomeça do 30, não do 1.
- ❑ **Time travel:** voltar a um estado anterior e seguir por outro caminho.
- ❑ **Human-in-the-loop:** interromper antes de uma ação sensível, esperar aprovação, continuar.
- ❑ **Depuração:** inspecionar o estado exato em qualquer ponto da execução.


Super-steps




Super-steps



Super-steps



Super-steps



Store

- ❑ Repositório chave-valor organizado por namespaces
- ❑ Independente de thread
- ❑ Valores são documentos JSON
- ❑ Busca por chave ou por similaridade semântica
- ❑ Persistência da memória de longo prazo: semântica, episódica, procedural, planos
- ❑ Acessível de dentro dos nós do grafo, em qualquer sessão

Estado x Checkpoint x Store

	Estado	Checkpoint	Store
Escopo	Execução atual	Uma thread	Todas as threads
Chave	—	<i>thread_id</i>	namespace + chave
Ciclo de vida	Enquanto o grafo roda	Enquanto a thread existir	Indefinido
Realiza	Memória de trabalho	Curto prazo entre turnos	Longo prazo
Recuperação	Direta, é o objeto	Automática, ao reinvocar	Explícita, por busca

Síntese

- ❑ Modelo de linguagem não tem memória.
- ❑ Contexto é onde o agente “pensa”
- ❑ Memória de trabalho: informações em uso
- ❑ Longo prazo: semântica, episódica e procedural
- ❑ Operações de gerenciamento
 - escrever, recuperar, atualizar e esquecer.
- ❑ Em LangGraph: **estado** (trabalho), **checkpoint** (curto prazo, por *thread*) e **store** (longo prazo, entre sessões)

Referências

- [1] TULVING, E. Episodic and semantic memory. In: TULVING, E.; DONALDSON, W. (org.). *Organization of Memory*. New York: Academic Press, 1972. p. 381-403.
- [2] BADDELEY, A.; HITCH, G. Working memory. *Psychology of Learning and Motivation*, v. 8, p. 47-89, 1974.
- [3] SUMERS, T.; YAO, S.; NARASIMHAN, K.; GRIFFITHS, T. Cognitive Architectures for Language Agents. *Transactions on Machine Learning Research (TMLR)*, 2024.
- [4] LIU, N. F. et al. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics (TACL)*, v. 12, p. 157-173, 2024.
- [5] LANGCHAIN. LangMem — Conceptual Guide: Long-term Memory in LLM Applications. Disponível em: langchain-ai.github.io/langmem/concepts/conceptual_guide
- [6] LANGCHAIN. LangGraph — Persistence: Checkpointers and Store. Documentação oficial. Disponível em: docs.langchain.com