
INSTITUTO DE COMPUTAÇÃO – UNICAMP
MO810A/MC959A – Sistemas Multiagentes com Modelos de
Linguagem
Prof. Dr. Julio Cesar dos Reis

Fase 1 – Proposta

*EduAgent-OS: Sistema Multiagente Local para Tutoria Ativa
e Gestão Longitudinal de Estudos*

Rafael Attilio Agricola – 249245
Jocielelio Castro Macedo Junior – 231722

1 Cenário e Contexto

O projeto insere-se no domínio de inteligência artificial aplicada à educação, com foco em sistemas multiagentes baseados em modelos de linguagem (LLMs). Considera-se o cotidiano de estudantes que precisam conciliar múltiplas disciplinas, materiais didáticos extensos, avaliações e compromissos pessoais ao longo de um período letivo. O público potencial inclui estudantes de graduação e do ensino médio/técnico; o recorte inicial do protótipo será o acompanhamento de disciplinas de graduação.

Nesse cenário, o estudante recebe planos de desenvolvimento de disciplinas (PDDs), cronogramas e materiais como PDFs e notas de aula. Precisa transformar essas informações em uma rotina viável, identificar o conteúdo prioritário para cada avaliação e selecionar recursos de apoio. Durante o estudo, novas dificuldades podem tornar insuficiente o planejamento original: um tópico exige mais prática, uma revisão precisa ser antecipada ou uma sessão não é concluída.

A literatura oferece elementos para apoiar esse processo. O MultiTutor explora agentes especializados para suporte educacional personalizado (Sun e Tai, 2025); o MetaGPT organiza a cooperação por papéis e procedimentos estruturados (Hong et al., 2024); e o MemGPT investiga continuidade conversacional por meio de uma hierarquia de memória (Packer et al., 2023). Esses resultados motivam investigar sua articulação em um assistente que conecte conteúdo, interação pedagógica, memória entre sessões e planejamento temporal, considerando os limites computacionais da execução local.

2 Motivação para o Tema

A proposta fundamenta-se principalmente no **ODS 4 – Educação de Qualidade**, ao buscar apoio à aprendizagem autônoma por meio de tutoria ativa e organização personalizada dos estudos. O mecanismo esperado de benefício é aproximar o planejamento daquilo que o estudante efetivamente demonstra compreender: dificuldades identificadas durante uma sessão devem orientar tanto as próximas atividades quanto a distribuição do tempo disponível.

Do ponto de vista científico, interessa investigar se a especialização de agentes e a memória longitudinal melhoram a consistência desse acompanhamento em relação a um assistente único. Também importa compreender o compromisso entre qualidade das respostas, fidelidade da memória e custo de contexto. Do ponto de vista tecnológico, o projeto articula orquestração, uso de ferramentas, recuperação de informação e gerenciamento de estado, em consonância com os temas da disciplina.

A execução local busca reduzir a dependência de serviços de inferência pagos e permitir continuidade com materiais já disponíveis quando não houver conexão. Essa orientação possui relação complementar com os **ODS 9 – Indústria, Inovação e Infraestrutura** e **10 – Redução das Desigualdades**. Entretanto, sua contribuição para acesso depende dos requisitos de hardware e do desempenho observado, que deverão ser caracterizados experimentalmente. O benefício esperado para o estudante é um apoio mais contínuo à organização e à reflexão sobre suas dificuldades, sem pressupor antecipadamente ganhos de aprendizagem.

3 Caracterização do Problema

O problema investigado é a dificuldade de manter um acompanhamento de estudos que integre, ao longo de múltiplas sessões, **mediação pedagógica ativa, histórico de aprendizagem e adaptação de cronogramas sob restrições reais de tempo**. Uma resposta correta a uma dúvida isolada não assegura que o estudante compreendeu o tópico, nem informa, por si só, como o restante do plano de estudos deve mudar.

A lacuna abordada possui três dimensões relacionadas:

1. **Integração entre tutoria e rotina.** O MultiTutor evidencia o potencial da especialização de agentes para explicações, recursos e atividades educacionais (Sun e Tai, 2025). A questão deste projeto é conectar esse suporte a decisões sobre tempo de estudo, prazos e revisões, utilizando evidências produzidas nas próprias interações.
2. **Continuidade e fidelidade do histórico.** O MemGPT caracteriza as limitações de janelas de contexto em conversas extensas e apresenta gerenciamento hierárquico de memória (Packer et al., 2023). No cenário educacional, permanece necessário determinar quais fatos recuperar e preservar, distinguindo respostas observadas, dificuldades recorrentes e estimativas de domínio que podem mudar com o tempo.
3. **Qualidade sob orçamento computacional limitado.** Acumular documentos, histórico e instruções de todos os agentes amplia o contexto processado. A reutilização seletiva de habilidades, explorada em outro domínio pelo Voyager (Wang et al., 2023), motiva investigar quanto de instrução é necessário para cada tarefa pedagógica e qual informação pode ser compactada sem comprometer a continuidade.

Esses trabalhos sustentam os desafios componentes, mas não demonstram, por si só, a eficácia de sua integração no cenário proposto. A ausência dessa integração pode levar à repetição de diagnósticos, recomendações incompatíveis com o tempo disponível e perda de informações relevantes entre sessões. Cientificamente, dificulta distinguir o benefício da colaboração entre agentes do efeito de apenas aumentar o número de chamadas ao modelo.

Questão de pesquisa. Em que medida uma arquitetura multiagente com memória longitudinal e gestão seletiva de contexto consegue integrar tutoria ativa e replanejamento de estudos, mantendo qualidade pedagógica e viabilidade temporal com recursos locais limitados?

Delimitação do escopo. Serão abordados materiais textuais e PDFs fornecidos pelo estudante, extração de tópicos e prazos, curadoria complementar de textos e vídeos existentes, sessões textuais de tutoria, exercícios e flashcards, acompanhamento por tópico e planejamento semanal ao longo de múltiplas sessões. O planejamento considerará avaliações, compromissos fixos, disponibilidade e atividades pessoais. A execução local abrangerá a inferência, a memória e a base de materiais; busca na web e sincronização com agenda externa dependerão de conexão.

Ficam fora do escopo a atribuição de notas institucionais, a substituição do PDD oficial, a geração de vídeos, o treinamento de um modelo fundacional e a integração com sistemas acadêmicos fechados. Síntese de voz e gamificação são extensões posteriores

ao núcleo textual. A avaliação inicial será controlada, com sequências de sessões e cenários de estudo, sem pretensão de comprovar impacto educacional em larga escala ou acompanhamento real de um semestre inteiro.

4 Proposta de Solução Conceitual

Propõe-se o **EduAgent-OS**, um sistema multiagente de orientação *local-first*, com orquestração em LangGraph e inferência local utilizando o **Bonsai 2**. Seu objetivo geral é integrar tutoria ativa, memória longitudinal e planejamento adaptativo em um ciclo no qual as evidências de cada sessão orientem as próximas ações pedagógicas e temporais.

Objetivos específicos. Organizar conteúdos e prazos por disciplina; conduzir atividades que solicitem participação e explicação do estudante; manter um histórico recuperável de progresso; gerar cronogramas compatíveis com as restrições informadas; e investigar a redução do contexto por recuperação seletiva, compactação e instruções específicas por tarefa.

4.1 Agentes e coordenação

A arquitetura compreende **cinco agentes especializados**, coordenados por uma camada de orquestração em grafo. Essa camada assume o papel de gerenciamento do fluxo: encaminha solicitações, acompanha o estado da sessão e aciona os agentes necessários. Os agentes podem compartilhar o mesmo LLM local, diferenciando-se por objetivos, ferramentas e informações acessadas.

1. **Curador de Conhecimento.** Recebe PDDs, cronogramas e materiais, identifica tópicos e datas e organiza uma base local por disciplina. Utiliza recuperação aumentada por geração (RAG) para fornecer trechos e referências ao Tutor. Quando houver conexão, poderá selecionar textos e vídeos existentes segundo pertinência ao tópico e nível de dificuldade. As fontes acompanham o conteúdo recuperado para permitir sua conferência.
2. **Tutor Adaptativo.** Conduz a interação com o estudante, utilizando perguntas sócráticas, pistas graduais, exercícios e explicações em linguagem acessível. Emprega a explicação com palavras próprias, inspirada na Técnica de Feynman, para estimular a explicitação do entendimento. Ajusta o apoio às respostas observadas e às preferências declaradas, sem tratar preferência de formato como prova de maior eficácia. Uma biblioteca de *skills* oferece instruções específicas para explicar conceitos, gerar flashcards e conduzir pequenos questionários.
3. **Monitor de Aprendizagem.** Analisa respostas a exercícios e explicações do estudante com critérios explícitos por tópico. Produz estimativas de domínio acompanhadas das evidências e de sua incerteza, identifica dificuldades recorrentes e recomenda revisões. Encaminha os registros ao Bibliotecário e solicita replanejamento quando houver necessidade de reforço ou mudança de prioridade. Sua avaliação é formativa, sem caráter de nota oficial.

4. **Planejador de Rotina e Agenda.** Combina tópicos, prazos, disponibilidade e indicações do Monitor para propor blocos de estudo e revisão. O LLM interpreta prioridades e explica as escolhas; uma ferramenta determinística de resolução de restrições verifica disponibilidade, duração e sobreposições. Se as exigências forem incompatíveis, o sistema explicita o conflito e solicita a revisão das restrições. Produz cronogramas exportáveis e poderá sincronizá-los com uma agenda externa, como Google Agenda, por integração via MCP.
5. **Bibliotecário de Memória.** Organiza registros episódicos das sessões, informações semânticas sobre perfil e conteúdos e sínteses reflexivas sobre dificuldades e estratégias utilizadas. Recupera apenas informações pertinentes à tarefa atual, preservando origem e ordem temporal. Atualiza o histórico após as sessões e atende consultas explícitas dos demais agentes, de modo que uma estimativa antiga não seja confundida com o estado atual do estudante.

A cooperação ocorre pela troca de informações estruturadas sobre disciplina, tópico, fontes, evidências, prioridade e ação solicitada. O grafo define as dependências entre essas etapas e mantém um estado compartilhado consistente. O *Model Context Protocol* (MCP) padroniza o acesso a ferramentas e dados; o protocolo *Agent-to-Agent* (A2A) será explorado na delegação entre componentes expostos como serviços, sem exigir que toda transição interna do grafo seja uma chamada remota.

4.2 Gestão de contexto e memória

O sistema organiza o contexto em três níveis complementares. **Dentro da sessão**, preserva as interações recentes e compacta trechos antigos em sínteses orientadas a objetivos, conceitos discutidos e dificuldades observadas. A compactação é acionada por um orçamento configurável e incorporada entre chamadas ao modelo, sem pressupor alteração do contexto durante uma geração em andamento. Os registros originais permanecem recuperáveis para conferir ou complementar as sínteses.

Entre sessões, o Bibliotecário recupera o histórico relevante por disciplina e tópico. **Por tarefa**, o Tutor carrega somente as instruções e ferramentas da habilidade necessária. A busca por instruções mais enxutas será tratada como hipótese experimental: diferentes versões serão comparadas quanto à qualidade e ao consumo de tokens, em vez de assumir que uma redução preserve automaticamente o desempenho.

4.3 Fluxo de funcionamento e resultados esperados

O funcionamento previsto segue um ciclo de seis etapas:

1. O estudante fornece materiais, avaliações, disponibilidade e compromissos; o Curador organiza o conteúdo e os prazos.
2. O Planejador consulta o histórico disponível e propõe uma agenda de estudos compatível com as restrições.
3. No início de cada sessão, o Bibliotecário recupera dificuldades e objetivos pertinentes, e o Curador disponibiliza os trechos de apoio.

4. O Tutor conduz atividades e solicita respostas ou explicações; o Monitor registra evidências de compreensão e necessidades de revisão.
5. O Bibliotecário consolida o progresso; quando necessário, o Planejador redistribui blocos futuros respeitando os compromissos existentes.
6. O sistema apresenta a atualização ao estudante e utiliza o novo estado para orientar a sessão seguinte.

Por exemplo, se o estudante apresentar dificuldade em um tópico próximo de uma avaliação, o Monitor recomenda reforço, o Bibliotecário registra a evidência e o Planejador procura um bloco disponível. O Tutor retoma esse tópico na sessão seguinte com uma atividade apropriada. Se não houver tempo suficiente, o sistema apresenta a incompatibilidade, em vez de produzir um cronograma inviável.

Espera-se obter um protótipo capaz de demonstrar esse ciclo e produzir registros para avaliação nas fases seguintes. A comparação inicial considerará um assistente único com acesso ao mesmo modelo, materiais e ferramentas. Serão observadas a qualidade e a fundamentação das respostas, a fidelidade da memória, o cumprimento das restrições de agenda, o sucesso das delegações e os custos em tokens, latência e memória computacional. Ablações de memória, compactação e seleção de *skills* permitirão investigar a contribuição de cada mecanismo, com controle dos recursos utilizados. Essas medidas avaliam o sistema; ganhos de aprendizagem humana exigiriam investigação adicional.

5 Posicionamento em Relação ao Estado da Arte

A seleção parte da lista [Awesome Agentic Systems](#), indicada pela disciplina, e de trabalhos complementares sobre suporte educacional, memória e uso de ferramentas. Foram priorizadas contribuições relacionadas aos componentes da questão de pesquisa. Para cada trabalho, distinguem-se o critério de seleção, o elemento aproveitado e sua adaptação ao projeto.

MetaGPT (Hong et al., 2024). **Seleção:** organização da colaboração multiagente por papéis e procedimentos padronizados. **Elemento extraído:** decomposição de tarefas e comunicação por artefatos estruturados, com verificação de resultados intermediários. **Adaptação:** substituir o fluxo de desenvolvimento de software por um ciclo educacional de curadoria, tutoria, acompanhamento e replanejamento. Os artefatos passam a representar tópicos, evidências de aprendizagem e restrições temporais.

MultiTutor (Sun e Tai, 2025). **Seleção:** aplicação direta de agentes especializados ao suporte personalizado ao estudante. **Elemento extraído:** cooperação para explicações, seleção de recursos, atividades e identificação de lacunas. **Adaptação:** priorizar interação textual ativa e conectar os registros das atividades à memória longitudinal e ao cronograma. O trabalho também contempla recursos interativos e multimodais; a contribuição pretendida aqui está na articulação com rotina e continuidade local, e não na alegação de que a tutoria multiagente anterior seja apenas estática.

MemGPT (Packer et al., 2023). **Seleção:** enfrentamento de janelas de contexto limitadas em análise documental e conversas com múltiplas sessões. **Elemento extraído:** separação entre contexto ativo e armazenamento externo, com movimentação seletiva de informação. **Adaptação:** definir uma política de memória pedagógica por tópico, preservando erros recorrentes, objetivos e evidências de progresso. A compactação será avaliada pela fidelidade das informações recuperadas e pela continuidade das tarefas.

Voyager (Wang et al., 2023). **Seleção:** reutilização de habilidades e refinamento a partir de retorno do ambiente. **Elemento extraído:** biblioteca de habilidades recuperáveis e aperfeiçoamento iterativo. **Adaptação:** substituir habilidades de código para Minecraft por procedimentos pedagógicos, como construção de flashcards e condução de questionários. A comparação entre instruções completas e reduzidas é uma investigação deste projeto, não um resultado estabelecido pelo Voyager.

ToRA (Gou et al., 2024). **Seleção:** integração entre raciocínio em linguagem natural e ferramentas computacionais. **Elemento extraído:** delegação de operações verificáveis a executores externos. **Adaptação:** utilizar resolução determinística de restrições para verificar cronogramas, enquanto o agente interpreta necessidades e prioridades. Essa transposição não exige reproduzir o treinamento do ToRA nem elimina erros na interpretação das entradas; torna verificável a viabilidade do plano frente às restrições formalizadas.

Em síntese, o diferencial proposto é a integração de **tutoria ativa, memória longitudinal e replanejamento orientado por evidências**, sob as restrições de execução local. A hipótese é que a especialização cooperativa e a gestão seletiva de contexto permitam um acompanhamento mais consistente sem crescimento descontrolado do custo de inferência. A confirmação dessa hipótese dependerá dos experimentos, cujos procedimentos detalhados serão definidos na fase de metodologia.

Declaração de uso de IA generativa no processo de elaboração

Durante a elaboração desta proposta, foram utilizados os modelos de IA generativa Claude Haiku 4.5, Muse Spark 1.2 Free e GPT-6-Astra para auxiliar na correção de erros ortográficos, na consolidação e nos ajustes de organização, clareza e formatação do texto. A revisão final e a responsabilidade pelo conteúdo submetido cabem aos autores; ferramentas de IA não integram a autoria do trabalho.

Referências

- Gou, Z.; Shao, Z.; Gong, Y.; Shen, Y.; Yang, Y.; Huang, M.; Duan, N.; Chen, W. (2024). ToRA: A Tool-Integrated Reasoning Agent for Mathematical Problem Solving. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/2309.17452>.
- Hong, S. et al. (2024). MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/2308.00352>.
- Packer, C.; Wooders, S.; Lin, K.; Fang, V.; Patil, S. G.; Stoica, I.; Gonzalez, J. E. (2023). MemGPT: Towards LLMs as Operating Systems. *arXiv preprint arXiv:2310.08560*. <https://arxiv.org/abs/2310.08560>.
- Sun, E.; Tai, L. (2025). MultiTutor: Collaborative LLM Agents for Multimodal Student Support. *Proceedings of the Innovation and Responsibility in AI-Supported Education Workshop*, PMLR, 273:174–190. <https://proceedings.mlr.press/v273/sun25a.html>.
- Wang, G.; Xie, Y.; Jiang, Y.; Mandlekar, A.; Xiao, C.; Zhu, Y.; Fan, L.; Anandkumar, A. (2023). Voyager: An Open-Ended Embodied Agent with Large Language Models. *arXiv preprint arXiv:2305.16291*. <https://arxiv.org/abs/2305.16291>.